盛子骥

手机/微信：18955269125　邮箱：sziji108@163.com



教育背景

本科：武汉大学 国家网络安全学院 2020.09-2024.06

网络空间安全专业

GPA：3.62/4.0（前30%）

- 武汉大学国家网络安全学院2020-2021学年度**优秀学生干部**

硕士：华中科技大学 网络空间安全学院 2024.09-2027.06

网络空间安全专业

研究方向： 多模态大模型、多智能体系统与大模型应用

GPA：3.81/4.0（前14%）

- **2026年度国家奖学金**、华中科技大学**优秀共青团员、三好学生**

实习经历

ByteDance 字节跳动 **算法实习生-LLM/Agent 方向** 2026.05-2026.09

Agent 输入语义理解与信息抽取

- **任务建模：** 面向 Agent 用户输入中的意图识别与对象、动作、目的地抽取需求，设计“MacBERT 意图识别—UIE 实体抽取—专项策略”三级架构，解耦通用语义能力与下游业务逻辑，支持数据外发等多场景复用。
- **数据建设：** 完成标签体系设计、模型选型与数据构建，累计建设 1万+意图分类样本、2.1万+实体抽取样本，支撑分类与抽取模型的训练及评测。
- **效果与性能：** 线上精标集意图识别平均 Precision、Recall 均达80%+；实体抽取 Macro-F1 达76%—78%，核心实体准确率85%+。通过推理流水线、分词处理及重复计算优化，将高QPS场景P99延迟控制在约400ms。

Agent 多源证据融合与数据流向识别

- **任务建模：** 针对多工具调用中数据读取、加工与传递过程难以关联的问题，将数据流向识别抽象为“敏感资源—外发动作—外部目的地”三元关系，构建跨环节证据链。
- **核心方案：** 设计GraphQL-like DSL，融合用户输入语义、ToolCall参数与OAPI执行证据，实现跨环节关联判定；统一敏感信息与话题边界，建设人工参与的数据标注、评测与迭代闭环。
- **项目成果：** 经渠道覆盖与话题误报归因迭代，离线评测中联合切面召回率达100%、准确率达98%；中风险送审规则命中占比由6.47%降至0.24%，高风险拦截规则命中占比由0.314%降至0.16%。

Agent 执行轨迹建模与状态追踪

- **任务背景：** 面向复杂 Agent 任务中的多工具调用与并行执行，解决离散检测结果难以关联、数据血缘难以追踪、执行过程难以回放的问题。
- **核心方案：** 参与设计“事实流—信息流—处置层”架构及 contextPlanner、Event 等研判信息协议，协同定义事实流事件与关键接口，通过统一事件表示支撑数据流转追踪与状态管理。
- **阶段成果：** 完成统一逻辑事实层、事实流投影、信息流与状态机初版方案及关键架构设计；搭建固定场景 Demo，验证离线风险发现能力，并推进主要流程串联与实时告警能力建设。

论文项目

大模型安全领域 **EMNLP 2025 Main conference（NLP领域顶会，CCF-B，一作）**

Merger-as-a-Stealer: Stealing Targeted PII from Aligned LLMs with Model Merging

提出了一种基于模型合并场景的隐私数据窃取攻击框架，通过有害微调将恶意模型注入合并流程，可绕过DPO/KTO等主流对齐防御机制，揭示了模型合并算法场景下的隐私安全风险。

多智能体系统应用 **ACL 2026 Main conference（NLP领域顶会，CCF-A，一作）**

LEARNERCOMPASS: Intelligent Tutoring System with Dynamic Cognitive Diagnosis and Multi-Model Path Planning

提出了一个端到端的个性化学习路径规划框架，融合动态知识图谱与Graph-RAG机制抑制大模型幻觉，并设计了基于多智能体编解码架构的实时认知诊断模块与AB-MCTS-M多模型路径规划算法，在STEM学科路径规划任务中显著优于基线方法。

多模态大模型幻觉缓解 **NeurIPS 2026 Main Track（人工智能领域顶会，CCF-A，一作）**

Object Hallucination Mitigation in Large Vision-Language Models via Self-Vision Dual Masking and Uncertainty-Triggered Assembly

针对 LVLM 物体幻觉及外部视觉专家带来的额外成本，提出免训练方法 SIGMA；利用模型自身生成支持/互补视觉掩码，并通过不确定性触发三流 Logit 组装进行动态校正。在多个LVLM和多个场景下达到SOTA效果。

多轮对话提示词注入攻击 **IEEE TIFS 2026 在审（共同一作）**

PersistInject: Persistent Prompt Injection Attacks against Multi-Turn LLM Applications

提出首个面向多轮交互的持久化提示注入攻击 PersistInject，通过将恶意指令嵌入模型回复并采用分阶段优化，使攻击者只需在首轮注入一次即可持续影响后续多轮响应，突破了多种先进的防御方法。

竞赛专利

第十八届挑战杯全国大学生课外学术科技作品竞赛“揭榜挂帅”专项赛 **(3/10)国家特等奖及擂主**
第十九届挑战杯全国大学生课外学术科技作品竞赛“揭榜挂帅”专项赛 **(负责人)国家一等奖**
第三届中国研究生网络安全创新大赛 **国家二等奖**
第四届中国研究生网络安全创新大赛 **(负责人)国家三等奖**
第十九届全国大学生信息安全竞赛（作品赛） **(负责人)国家三等奖**
第十五届“挑战杯”建设银行中国大学生创业计划竞赛“揭榜挂帅”专项赛 **国家三等奖**
多智能体应用/可信应用方向发明专利 **3项已授权发明专利(均为导师第一本人第二)**

项目经历

基于信创的学习迁移模型构建知识图谱（国家级特等奖及擂主项目） 2023.03-2023.09

项目背景： 由中国软件与技术服务股份有限公司所提供的课题，目的是实现结构化和非结构化数据知识图谱的智能构建

主要贡献： 项目**主要贡献者（rank:3/10）**，主要负责实体关系抽取任务的实现以及数据标注方案的制定及调整

项目内容： 项目采用paddleUIE实现实体关系抽取，并多次结合模型训练结果调整数据标注方案，采用pydatalog+KG-BERT实现知识推理与补全，采用Dedupe实现实体消歧与融合，采用neo4j作为图数据库，并最终实现了国产软硬件的兼容

基于多智能体深度推理的自适应学习路径动态规划（国家级一等奖项目） 2025.05-2025.10

项目背景： 赛题由**科大讯飞**发布，针对大模型在教育应用中诊断不准、路径固化、易生“幻觉”的核心痛点，研发新一代**多Agent协同**的个性化学习系统

主要贡献： 作为**项目负责人**，方案设计，知识图谱、学习路径规划等多模块算法开发

项目内容： 提出“深度推理大模型 + 动态知识图谱 + 多智能体”三位一体的闭环框架 。**核心技术1：**通过Graph-RAG与自适应动态知识图谱构建可信推理引擎，解决“幻觉”问题 。**核心技术2：**利用多智能体认知诊断（动态编解码器架构）实现对学习者认知状态的精准评估 。**核心技术3：**采用AB-MCTS-M路径融合算法与Reflexion反思机制，动态生成并优化个性化学习路径 。

基于动态时序RAG构建的混合专家多智能体网络告警日志研判系统 2025.07-2025.10

项目背景： 命题由**天融信**发布，旨在通过大模型与Agent解决安全运营中心(SOC)面临的“告警洪流”与“研判疲劳”问题

项目成果： 全面完成命题的各项核心挑战，实现了对海量告警的自动化深度研判，显著提升了告警研判的准确性与效率

主要贡献： 作为**项目负责人**，负责系统的架构设计、时序RAG系统、混合专家Agent系统的研发实现

项目内容： 提出业界首创的“漏斗分层 + RAG + MoE”架构，结合分诊与研判，高效平衡分析精度与资源。核心技术包括：**三维动态RAG引擎：**融合内外部与动态时序知识，提供深度情境感知。**多智能体协同研判：**应用知识蒸馏创建轻量级专家智能体，基于LangGraph由中心节点(Qwen3-4B)动态编排工作流。**混合动态知识库：**集成Redis(热/时序)、Milvus(温/向量)与Neo4j(图谱)，构建“温热”双层知识存储。

基于人机混合智能的XX协同XX技术研究（省部级项目） 2024.11—2026.05

项目背景： 面向复杂动态环境下信息不完备、任务约束多变以及单一智能决策适应性不足等问题，研究融合人员经验与智能算法的协同规划方法，提升规划过程的适应性、可靠性。

项目成果： 完成原型系统及项目验收

主要贡献： 担任项目**学生负责人**，负责研究任务拆解、总体技术路线设计、三项核心模块研发推进及跨模块方案协同，统筹阶段材料整理与项目成果交付。

项目内容： 构建“人机混合决策—态势弹性知识库—人机共生协同演进”一体化技术框架。**核心模块1：**人机混合决策，融合人员经验、任务约束与算法生成结果，通过多方案生成、交互反馈和约束校验实现协同规划与动态优化；**核心模块 2：**弹性知识库，研究多源知识的统一表示、关联组织、动态更新与按需检索，为环境变化下的知识重组和规划推演提供支撑；**核心模块 3：**人机共生协同演进，基于任务反馈构建能力评估与策略迭代机制，持续优化人机分工和协作模式，提升系统面对动态变化的适应能力。