



教育背景

本科：武汉大学 国家网络安全学院

2020.09-2024.06

网络空间安全专业

GPA：3.62/4.0

• 武汉大学国家网络安全学院2020-2021学年度**优秀学生干部**

硕士：华中科技大学 网络空间安全学院

2024.09-2027.06

网络空间安全专业

研究方向：可信大模型与多智能体系统的安全、对齐及应用

GPA：3.83/4.0

• **国家奖学金**、华中科技大学**优秀共青团员**、**三好学生**

实习经历

字节跳动·飞书 | LLM/Agent 安全算法实习生

2026.05-2026.08

Agent系统用户输入侧意图识别风控通用能力建设

- **需求背景**：Agent 输入既要识别风险意图，也要抽取对象、动作和目的地；单一分类模型无法支撑数据外发等多场景复用，因此负责建设输入侧通用语义底座。
- **核心方案**：设计“L1 MacBERT 意图识别—L2 UIE 实体抽取—L3 专项策略”三级架构，解耦通用能力与业务规则；完成标签设计、模型选型和数据闭环，累计构建 1 万+意图分类、2.1 万+实体抽取数据。
- **项目成果**：线上精标集 MacBERT 平均 Precision/Recall 80%+，UIE Macro-F1 76%—78%、核心实体准确率 85%+；优化 pipeline、tokenizer 和重复计算，将高QPS场景 P99 控制在约 400 ms。

Agent系统数据外发风险识别

- **需求背景**：敏感数据可能经历读取、加工和多工具调用，单个切面无法回答“什么数据通过何种动作流向哪里”，容易造成外发风险漏放或误召。
- **核心方案**：将风险抽象为“敏感资源—外发动作—外部目的地”，设计跨切面证据链与 GraphQL-like DSL，联合Input语义、ToolCall参数和OAPI执行证据；同步对齐敏感信息/话题边界，建设 HITL 数据与评测闭环。
- **项目成果**：中风险送审规则命中占比由 6.47% 收敛至 0.24%，高风险拦截规则命中占比由 0.314% 收敛至 0.16%；针对一期渠道覆盖和话题误报完成归因迭代，离线评测联合切面召回率 100%、准确率 98%。

Agent安全 Gen2 检测架构

- **需求背景**：现有检测器仅保存单点离散命中，无法追溯复杂 Agent 任务中的数据血缘、风险传播和并行执行状态，检测结果也难以回放与解释。
- **核心方案**：“事实流—信息流—处置层”框架，以及contextPlanner、Event等研判信息协议；协同对齐事实流事件与关键接口，搭建Demo验证离线风险发现能力并进一步推进实时风险告警。
- **阶段成果**：已完成统一逻辑事实层、事实流投影、信息流、状态机初版方案和关键架构设计，开始在固定 Demo 中串联主要流程；

论文项目

大模型安全领域

EMNLP 2025 Main conference (NLP领域顶会, CCF-B, 一作)

Merger-as-a-Stealer: Stealing Targeted PII from Aligned LLMs with Model Merging

提出了一种基于模型合并场景的隐私数据窃取攻击框架，通过有害微调将恶意模型注入合并流程，可绕过DPO/KTO等主流对齐防御机制，揭示了模型合并算法场景下的隐私安全风险。

多智能体应用领域

ACL 2026 Main conference (NLP领域顶会, CCF-A, 一作)

LEARNERCOMPASS: Intelligent Tutoring System with Dynamic Cognitive Diagnosis and Multi-Model Path Planning

提出了一个端到端的个性化学习路径规划框架，融合动态知识图谱与Graph-RAG机制抑制大模型幻觉，并设计了基于多智能体编解码架构的实时认知诊断模块与AB-MCTS-M多模型路径规划算法，在STEM学科路径规划任务中显著优于基线方法。

多模态大模型可信

NeruIPS 2026 Main conference (人工智能领域顶会, CCF-A, 一作)

Object Hallucination Mitigation in Large Vision-Language Models via Self-Vision Dual Masking and Uncertainty-Triggered Assembly

针对 LVLMM 物体幻觉及外部视觉专家带来的额外成本，提出免训练方法 SIGMA；利用模型自身生成支持/互补视觉掩码，并通过不确定性触发三流 Logit 组装进行动态校正。在多个LVLMM和多个场景下达到SOTA效果。

多轮对话提示词注入攻击

IEEE TIFS 2026 在审 (共同一作)

PersistInject: Persistent Prompt Injection Attacks against Multi-Turn LLM Applications

提出首个面向多轮交互的持久化提示注入攻击 PersistInject，通过将恶意指令嵌入模型回复并采用分阶段优化，使攻击者只需在首轮注入一次即可持续影响后续多轮响应，突破了多种先进的防御方法。

竞赛专利

第十八届挑战杯全国大学生课外学术科技作品竞赛“揭榜挂帅”专项赛	国家特等奖及擂主
第十九届挑战杯全国大学生课外学术科技作品竞赛“揭榜挂帅”专项赛	国家一等奖
第三届中国研究生网络安全创新大赛	国家二等奖
第四届中国研究生网络安全创新大赛	国家三等奖
第十九届全国大学生信息安全竞赛（作品赛）	国家三等奖
多智能体安全/可信应用方向发明专利	3项已授权专利（均为导师第一本人第二）

项目经历

基于信创的学习迁移模型构建知识图谱（国家级特等奖及擂主项目）2023.03-2023.09

项目背景：由中国软件与技术服务股份有限公司所提供的课题，目的是实现结构化和非结构化数据知识图谱的智能构建

主要贡献：项目**主要贡献者（rank:3/10）**，主要负责实体关系抽取任务的实现以及数据标注方案的制定及调整

项目内容：项目采用paddleUIE实现实体关系抽取，并多次结合模型训练结果调整数据标注方案，采用pydatalog+KG-BERT实现知识推理与补全，采用Dedupe实现实体消歧与融合，采用neo4j作为图数据库，并最终实现了国产软硬件的兼容

基于多智能体深度推理的自适应学习路径动态规划（国家级一等奖项目）2025.05-2025.10

项目背景：赛题由科大讯飞发布，针对大模型在教育应用中诊断不准、路径固化、易生“幻觉”的核心痛点，研发新一代**多Agent协同**的个性化学习系统

主要贡献：作为**项目负责人**，方案设计，知识图谱、学习路径规划等多模块算法开发

项目内容：提出“深度推理大模型 + 动态知识图谱 + 多智能体”三位一体的闭环框架。**核心技术1：**通过Graph-RAG与自适应动态知识图谱构建可信推理引擎，解决“幻觉”问题。**核心技术2：**利用多智能体认知诊断（动态编解码器架构）实现对学习者认知状态的精准评估。**核心技术3：**采用AB-MCTS-M路径融合算法与Reflexion反思机制，动态生成并优化个性化学习路径。

基于动态时序RAG构建的混合专家多智能体网络告警日志研判系统2025.07-2025.10

项目背景：命题由天融信发布，旨在通过大模型与Agent解决安全运营中心(SOC)面临的“告警洪流”与“研判疲劳”问题

项目成果：全面完成命题的各项核心挑战，实现了对海量告警的自动化深度研判，显著提升了告警研判的准确性与效率

主要贡献：作为**项目负责人**，负责系统的架构设计、时序RAG系统、混合专家Agent系统的研发实现

项目内容：提出业界首创的“漏斗分层 + RAG + MoE”架构，结合分诊与研判，高效平衡分析精度与资源。核心技术包括：**三维动态RAG引擎：**融合内外部与动态时序知识，提供深度情境感知。**多智能体协同研判：**应用知识蒸馏创建轻量级专家智能体，基于LangGraph由中心节点(Qwen3-4B)动态编排 workflow。**混合动态知识库：**集成Redis(热/时序)、Milvus(温/向量)与Neo4j(图谱)，构建“温热”双层知识存储。

基于人机混合智能的XX协同XX技术研究（省部级项目）2024.11—2026.05

项目背景：面向复杂动态环境下信息不完备、任务约束多变以及单一智能决策适应性不足等问题，研究融合人员经验与智能算法的协同规划方法，提升规划过程的适应性、可靠性。

项目成果：完成原型系统及项目验收

主要贡献：担任项目**学生负责人**，负责研究任务拆解、总体技术路线设计、三项核心模块研发推进及跨模块方案协同，统筹阶段材料整理与项目成果交付。

项目内容：构建“人机混合决策—态势弹性知识库—人机共生协同演进”一体化技术框架。**核心模块1：**人机混合决策，融合人员经验、任务约束与算法生成结果，通过多方案生成、交互反馈和约束校验实现协同规划与动态优化；**核心模块2：**弹性知识库，研究多源知识的统一表示、关联组织、动态更新与按需检索，为环境变化下的知识重组和规划推演提供支撑；**核心模块3：**人机共生协同演进，基于任务反馈构建能力评估与策略迭代机制，持续优化人机分工和协作模式，提升系统面对动态变化的适应能力。